

INFORME FINAL

Proyecto Integrador – Minería de Datos I

Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial

Alumno: Julio César Monge Roldán

1. Contexto y Objetivo

El presente proyecto fue desarrollado como Trabajo Integrador de la asignatura **Minería de Datos I**, con el propósito de aplicar las principales etapas del proceso de minería de datos sobre un conjunto de datos real correspondiente a usuarios de una plataforma de streaming.

El objetivo principal consistió en inspeccionar, preparar y analizar el conjunto de datos mediante técnicas estadísticas y de análisis exploratorio, aplicando posteriormente el **Análisis de Componentes Principales (PCA)** para reducir la dimensionalidad del problema y facilitar la interpretación de la información. Como complemento, se desarrolló una aplicación interactiva utilizando **Streamlit**, destinada a comunicar los resultados obtenidos de forma clara e intuitiva.

2. Dataset y calidad inicial

El conjunto de datos original fue proporcionado en formato **JSON** y contenía información correspondiente a usuarios de una plataforma de streaming, incluyendo variables demográficas, preferencias de contenido y hábitos de consumo.

Durante la etapa de inspección inicial se analizó la estructura del dataset, identificando los tipos de datos presentes, la existencia de valores faltantes, registros inconsistentes y diferentes oportunidades de mejora antes de comenzar el análisis.

3. Limpieza y preparación de los datos

La etapa de preparación tuvo como finalidad obtener un conjunto de datos consistente y apto para el análisis.

Las principales tareas realizadas fueron:

- tratamiento de valores faltantes;
- estandarización de nombres y categorías;
- corrección de inconsistencias detectadas en diferentes variables;
- conversión de tipos de datos cuando fue necesario;
- generación del conjunto de datos limpio (dataset_final.csv), utilizado durante el resto del proyecto.

Este proceso permitió mejorar significativamente la calidad de los datos y garantizar la confiabilidad de los análisis posteriores.

4. Hallazgos del análisis exploratorio (EDA)

El Análisis Exploratorio de Datos permitió comprender las principales características del conjunto de datos mediante estadísticas descriptivas y visualizaciones interactivas.

Entre los principales resultados obtenidos se destacan:

- análisis de la distribución de las variables numéricas;
- identificación de posibles valores atípicos mediante diagramas de caja;
- exploración de las variables categóricas y su frecuencia;
- análisis de correlaciones entre variables numéricas.

5. Análisis de Componentes Principales (PCA)

Luego del escalamiento de las variables numéricas se aplicó el **Análisis de Componentes Principales (PCA)** con el objetivo de reducir la dimensionalidad del conjunto de datos conservando la mayor cantidad posible de información.

La representación bidimensional de las observaciones mediante los dos primeros componentes facilitó la visualización de patrones generales presentes en el conjunto de datos y permitió sintetizar la información original utilizando un menor número de dimensiones.

6. Conclusiones y limitaciones

El proyecto permitió recorrer de manera completa las principales etapas del proceso de minería de datos, desde la inspección inicial del conjunto de datos hasta la interpretación de los resultados obtenidos mediante técnicas de análisis multivariado.

La combinación de notebooks desarrolladas en Python y una aplicación interactiva en Streamlit favoreció tanto la reproducibilidad del análisis como la comunicación de los resultados.

Como principales limitaciones del trabajo, debe considerarse que el PCA únicamente analiza relaciones lineales entre variables numéricas y que los resultados obtenidos dependen directamente de la calidad del conjunto de datos utilizado.

Como trabajo futuro podrían incorporarse nuevos registros, evaluar otras técnicas de reducción de dimensionalidad e implementar modelos predictivos utilizando el conjunto de datos preparado.

7. Enlaces

Repositorio de GitHub:

https://github.com/Juliocmonger1994/PI_Mineria_Datos_1.git

Aplicación Streamlit:

<https://pimineriadatos1-juliocmonger.streamlit.app/>